



Econométrie des données qualitatives

Analyse économétrique des déterminants de l'accès à l'enseignement supérieur

Réalisé par :

BALTAGI Reina

GHALIOUNJI Nouran

EL-BAIDAK Houda

Master 1- Parcours BIDABI

Le 19/05/2025

I. Introduction

L'orientation vers l'enseignement supérieur demeure un enjeu central des politiques éducatives. Pour cela, comprendre les déterminants individuels et familiaux de cette orientation permet d'identifier les leviers susceptibles de réduire les inégalités d'accès. L'objectif de cette étude est d'examiner l'influence du rendement scolaire (GPA), du capital éducatif des parents (*pared*) et du statut de l'établissement (*public*) sur la probabilité qu'un élève ait envie de poursuivre des études supérieures (*apply*), mesurée sur une échelle ordinale à trois modalités : **peu probable, probable, très probable**. Dans un premier temps, une analyse descriptive sera menée afin de mettre en lumière les grandes tendances du jeu de données. Dans un second temps, plusieurs modèles économétriques seront estimés pour identifier les variables les plus significatives et comprendre leur effet. Enfin, une section de diagnostics et de visualisations permettra d'approfondir l'interprétation du modèle retenu et d'évaluer la qualité des prédictions produites.


II. Analyse descriptive des variables

Le jeu de données dont nous disposons contient 400 observations et quatre variables clés : *apply*, *gpa*, *pared*, et *public*. Il permet d'étudier l'influence du parcours scolaire, le contexte familial ou le type d'établissement fréquenté sur l'intention de poursuivre des études supérieures.

Variable	Description	Type
<i>apply</i>	Propension déclarée à postuler dans le supérieur (1 = peu probable, 2 = probable, 3 = très probable)	Ordinale
<i>gpa</i>	Moyenne scolaire sur 4 points	Continue
<i>pared</i>	1 si au moins un parent détient un diplôme de l'enseignement supérieur	Binaire
<i>public</i>	1 si l'établissement est public	Binaire

1. Présentation de la variable dépendante : Apply

La variable principale à expliquer 'apply', mesure la probabilité perçue par les étudiants de postuler à l'université, c'est une variable ordinale à 3 modalités : unlikely (improbable), somewhat likely (peu probable), very likely (très probable).




Dans notre échantillon, 55% des étudiants se déclarent peu susceptibles de postuler (unlikely) soit 220 sur 400. 35% se disent moyennement susceptibles (somewhat likely) soit 140 étudiants et enfin seulement 10% (soit 40 étudiants) se disent très susceptibles de postuler (very likely). Cette répartition montre une forte concentration vers les intentions faibles ou hésitantes, possiblement liée à des freins socio-économiques ou informationnels. Ces premiers résultats seront approfondis par les analyses économétriques à

venir en mobilisant notamment le niveau scolaire (*gpa*), le niveau d'éducation des parents (*pared*) et le type d'établissement fréquenté (*public*).

2. Variables explicatives :

2.1. Performance scolaire : GPA


La première variable étudiée est le *gpa*, c'est une variable quantitative qui mesure la performance académique de chaque élève sur une échelle continue allant de 0 à 4. Plus le *gpa* est élevé, plus les résultats scolaires de l'élève sont meilleurs.



Selon le résumé statistique, le *gpa* des étudiants varie entre 1.9 et 4.0, avec une moyenne de 2.999 et une médiane de 2.990. Ces valeurs très proches suggèrent une distribution relativement symétrique et équilibrée. Ces résultats scolaires observés dans l'échantillon sont globalement bons, ce qui laisse penser qu'il pourrait exister une relation positive entre *gpa* et *apply*. Un bon *gpa* pourrait renforcer les intentions des élèves à poursuivre des études supérieures, alors qu'un mauvais *gpa* pourrait au contraire les freiner, cette hypothèse sera testée dans les analyses économétriques à venir.

2.2. Capital éducatif familial : Pared


La variable '*pared*' mesure le niveau d'étude des parents. Elle indique si au moins l'un des deux parents de l'élève a poursuivi des études supérieures. Il s'agit d'une variable binaire, 0 correspond à aucun parent diplômé et 1 à au moins un parent diplômé.



Dans l'échantillon, 84,2 % des élèves n'ont aucun parent diplômé de l'enseignement supérieur, contre seulement 15,8 % qui en ont au moins un. Cette répartition reflète un fort déséquilibre et suggère une origine sociale globalement modeste. Ce contexte familial peut influencer les intentions de poursuivre les études supérieures : les élèves dont les parents ne sont pas passés par l'université peuvent manquer d'informations, de soutien, ou de légitimité perçue. Nous pouvons ainsi supposer que le fait d'avoir au moins un parent diplômé favoriserait l'intention de poursuivre des études supérieures, une deuxième hypothèse que les analyses suivantes permettront de vérifier.

2.3. Type d'établissement : Public

La variable public qui indique si l'élève a fréquenté un établissement public ou privé au premier cycle (graduate school). Elle est binaire : 0 correspond à un établissement privé et 1 à un établissement public.




Dans l'échantillon, 85,8 % des élèves sont issus d'établissements privés, contre seulement 14,2 % du public. Ce déséquilibre est à prendre en compte dans l'interprétation des résultats. Il est possible que le type d'établissement joue un rôle dans l'intention de poursuivre des études, notamment à travers les différences de ressources, d'accompagnement ou de réseau. Nous posons donc une troisième hypothèse : fréquenter un établissement public pourrait influencer positivement ou négativement l'intention de postuler.

3. Analyse croisée entre *apply* et les variables explicatives

3.1. Apply et GPA

3.1.1. Distribution et tendance visuelle



Nous commençons ici l'analyse des relations entre les variables, en observant dans un premier temps le lien entre la variable *apply* et le *gpa*, illustré par le graphique ci-contre. Nous constatons que la médiane du *gpa* augmente progressivement entre les groupes : “unlikely”, “somewhat likely” et “very likely”, ce qui suggère clairement une relation positive entre la performance scolaire et l'intention de postuler à l'université. Cela dit, les valeurs restent globalement proches. Les distributions présentent de nombreuses similitudes : les quartiles sont proches d'un groupe à l'autre, et les valeurs extrêmes (faibles comme

élevées) apparaissent dans chaque catégorie. Cela montre que le *gpa* seul ne suffit pas à prédire avec certitude les intentions. D'autres facteurs sont considérés, ce que les prochaines analyses vont montrer.


3.1.2. Confirmation statistique par test ANOVA

```
> summary(aov(gpa~apply,data = df_clean))
              Df Sum Sq Mean Sq F value    Pr(>F)
apply          2    1.50   0.7487    4.819 0.00856 **
Residuals    397   61.69   0.1554
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Un test ANOVA a été réalisé afin d'évaluer si la moyenne du GPA variait de manière significative selon la probabilité perçue de postuler à l'université. Le test renvoie une p-valeur de

0.00856, inférieur au seuil classique de 5%, ce qui permet de rejeter l'hypothèse nulle d'égalité des moyennes entre les groupes. Ce résultat statistique confirme que la performance scolaire moyenne diffère selon les modalités de la variable *apply* et vient renforcer l'analyse descriptive effectuée plus tôt à partir du boxplot : le lien entre performance académique et intention de poursuite d'études est non seulement visible graphiquement, mais également confirmé sur le plan statistique.


3.2. Apply et Pared



La part d'étudiants ayant au moins un parent diplômé augmente progressivement avec la probabilité perçue de postuler. Elle est d'environ 10 % chez les 'unlikely', passe à environ 20–25 % chez les 'somewhat likely', et atteint un peu plus de 30 % chez les 'very likely'. Cette évolution, visible dans le graphe, soutient l'idée selon laquelle le contexte familial, et en particulier le fait d'avoir des parents diplômés, peut jouer un rôle important dans l'intention de poursuivre ses études. Toutefois, les

étudiants issus de familles non diplômées restent majoritaires dans chaque groupe, ce qui montre que ce facteur, bien qu'important, ne suffit pas lui seul pour expliquer les intentions.

3.3. Apply et Public



La répartition des élèves selon le type d'établissement d'origine présente un comportement clairement différent de celui observé pour les autres variables explicatives "gpa" et "pared". La part des étudiants issus du public est d'environ 14% chez les "unlikely", baisse à environ 11% chez les "somewhat likely", puis remonte à près de 26% chez les "very likely".

Cette évolution non linéaire suggère que l'effet du type de l'établissement est moins direct que celui des autres variables explicatives ou pourrait être dû

au hasard. Cela justifie une attention particulière dans la modélisation économétrique à venir.

4. Premiers enseignements de l'analyse descriptive

D'après les premières observations, certaines tendances ressortent clairement. D'un côté, les élèves ayant un gpa plus élevé, ou au moins un parent diplômé, semblent plus enclins à envisager des études supérieures. Chacun de ces deux facteurs paraît avoir un effet positif sur l'intention de postuler. Toutefois, la variable liée au type d'établissement (public ou privé) évolue de manière moins régulière, et reste plus difficile à interpréter. Ces premiers constats méritent d'être testés plus formellement à travers un modèle économétrique, afin de vérifier si ces observations initiales sont statistiquement significatives et de mieux comprendre leur poids réel.

III. Modélisation

1. Cadre théorique et choix méthodologique

A. Le modèle Logit

Un modèle logit (ou régression logistique) est une méthode statistique utilisée lorsque nous cherchons à expliquer ou à prédire la probabilité d'occurrence d'un événement à partir d'un ensemble de variables explicatives quantitatives ou qualitatives. Contrairement à la régression linéaire, qui peut produire des valeurs négatives ou supérieures à 1, le logit garantit que les probabilités estimées restent toujours entre 0 et 1.

Il existe plusieurs modèles logit qui peuvent être utilisés en fonction du type de notre variable expliquée. Dans le cadre de ce rapport nous allons distinguer entre ces 3 modèles Logit mais cependant il en existe bien d'autres :

- Logit binaire : estime la probabilité d'un événement 0/1.
- Logit ordinal : Utilisé pour des réponses graduées ; exploite l'ordre naturel. S'appuie sur l'hypothèse que l'effet des variables est constant d'une coupure à l'autre (proportional odds).
- Logit multinomial : Quand les catégories ne s'ordonnent pas

Dans le cadre de notre étude, notre variable dépendante (celle que nous cherchons à expliquer) n'est autre que la variable *apply* qui est ordonnée sous 3 catégories :

- Peu probable
- Probable
- Très probable

Le **modèle logit ordonné** convertit chaque modalité de la variable en un ensemble de probabilités cumulées, transformées par la fonction logistique.

1.1 L'hypothèse des lignes parallèles

Le modèle postule que l'effet d'une variable explicative est **constant** d'un seuil à l'autre : un point de GPA supplémentaire accroît de la même manière la chance de passer de *peu probable* à *probable* que de *probable* à *très probable*. Cette propriété est la condition de **proportionnalité des cotes** ou « lignes parallèles ».

2. Stratégie d'estimation

Quatre modèles imbriqués sont estimés :

1. **Modèle nul** (aucune variable explicative) référence.

2. **Modèle 1** : *gpa* uniquement.
3. **Modèle 2** : *gpa* + *pared*.
4. **Modèle 3** : *gpa* + *pared* + *public*.
5. **Modèle 4** : *gpa***pared* + *public*

Nous estimons chacun de ces modèles et nous nous basons sur l’AIC afin de retenir le modèle avec le meilleur pouvoir explicatif qui soit le moins complexe.

3. Résultats

Modèle	Variables incluses	Coef GPA (p-val)	Coef Pared (p-val)	Coef Public (p-val)	Interaction GPA×Pared (p-val)	Log-vraisemblance	AIC
Modèle 0	Aucune	–	–	–	–	-370.60	745.21
Modèle 1	GPA	0.7249 (p = 0.0036)	–	–	–	-366.30	738.60
Modèle 2	GPA, Pared	0.6042 (p = 0.0173)	1.0457 (p < 0.001)	–	–	-358.53	725.06
Modèle 3	GPA, Pared, Public	0.6158 (p = 0.0182)	1.0477 (p < 0.001)	-0.0587 (p = 0.8438)	–	-358.51	727.02
Modèle 4	GPA, Pared, Public, GPA×Pared (interaction)	0.5918 (p = 0.0363)	0.5875 (p = 0.7827)	-0.0621 (p = 0.8351)	0.1484 (p = 0.8277)	-358.49	728.98

En s’appuyant sur le Critère d’Information d’Akaike (AIC) et des tests du rapport de vraisemblance nous avons vu que :

4.1. Modèle nul

$$Y_i^* = \alpha + \varepsilon_i$$

Le modèle nul sert de référence dans l'analyse. Il ne comprend aucune variable explicative, uniquement les seuils qui séparent les trois modalités de la variable dépendante (apply). Il permet de modéliser la distribution globale des intentions de poursuivre des études supérieures sans tenir compte des caractéristiques des élèves

4.2. Modèle 1

$$Y_i^* = \beta_1 \times GPA_i + \varepsilon_i$$

Dans le premier modèle, l'effet du GPA est significatif sur la probabilité qu'un élève fasse des études supérieures. Chaque point supplémentaire augmente de manière significative la probabilité d'appartenir à une catégorie plus favorable. Ce modèle met d'emblée en évidence l'importance du rendement scolaire comme déterminant individuel de l'orientation post-bac, indépendamment du contexte familial ou institutionnel.

4.3. Modèle 2

$$Y_i^* = \beta_1 \times GPA_i + \beta_2 \times PARED_i + \varepsilon_i$$

Dans la deuxième modèle l'effet du GPA et du niveau d'éducation des parents sont tous les deux significatifs et une amélioration de l'AIC est remarquée entre le modèle qui inclut uniquement la moyenne de l'élève et celui-ci. Il s'agit également du modèle qui minimise au mieux l'AIC et qui offre donc le meilleur compromis entre la précision et la qualité. Nous remarquons également que lorsqu'on inclut l'effet de l'éducation des parents, le coefficient de la variable explicative GPA baisse, comme si son effet était réduit une fois que l'on contrôle par l'éducation des parents (de 0.7247 à 0.6158). En d'autres termes, une partie de l'impact initialement attribué au GPA reflétait en réalité le contexte familial dans lequel s'inscrit la performance scolaire. Le fait d'avoir des parents diplômés peut à la fois favoriser de meilleurs résultats scolaires (via un accompagnement éducatif, un soutien culturel, etc.) et renforcer l'aspiration à poursuivre des études supérieures. Lorsque l'on contrôle pour ce facteur, le coefficient du GPA diminue car on isole son effet propre, net de l'influence du milieu familial.

4.4. Modèle 3 :

$$Y_i^* = \beta_1 \times GPA_i + \beta_2 \times PARED_i + \beta_3 \times PUBLIC_i + \varepsilon_i$$

Dans le troisième modèle, on inclut toutes les variables (GPA, éducation des parents, et le fait d'être ou non dans une école privée) et on observe que seulement les moyennes des élèves et le niveau éducatif des parents restent significatifs. Le fait d'être ou non dans une école privée ne semble pas avoir un effet significatif sur le fait d'intégrer des études supérieures. C'est un résultat qui est un peu surprenant car d'un point de vue économique on s'attend à ce que le fait d'être scolarisé dans une école privée exerce un effet positif sur la probabilité d'envisager des études supérieures au vu des ressources supplémentaires qui s'offrent à l'élève et des réseaux sociaux professionnels plus denses qui s'offrent à lui. Néanmoins, il semble que le niveau scolaire (GPA) et le niveau d'éducation des parents capturent à eux seuls la plus grande partie des différences structurelles entre les élèves du public et du privé. Cela expliquerait donc pourquoi une fois que l'on contrôle ces variables, le statut de l'établissement n'ajoute pas une information significative dans notre modèle.

4.5. Modèle 4:

$$Y_i = \beta_1 \times GPA_i + \beta_2 \times PARED_i + \beta_3 \times PUBLIC_i + \varepsilon_i$$

Dans le quatrième modèle, nous avons testé une interaction entre le GPA et l'éducation des parents afin de vérifier si l'effet du rendement scolaire sur l'orientation vers le supérieur varie selon le contexte familial. L'objectif était d'examiner si un bon dossier académique a le même poids pour les élèves issus de milieux plus ou moins diplômés. L'interaction entre $GPA \times pared$ s'est révélée être non significative ce qui nous indique l'effet de la moyenne de l'élève sur la probabilité d'envisager des études supérieures est stable selon le niveau d'éducation des parents, et ces variables ont donc un effet propre et indépendant, sans un effet combiné sur l'échantillon.

5.1 Interprétation des coefficients du modèle retenu (Modèle 2)

- **Effet du GPA ($\beta = 0,60$)** : chaque point supplémentaire obtenu dans le GPA augmente d'environ 80 % la cote (odds) d'appartenir à une catégorie supérieure. Autrement dit, un élève passant de 2 / 4 à 3 / 4 voit sa cote d'appartenir à une catégorie supérieure augmenter de 80%.
- **Effet de l'éducation parentale ($\beta = 1,05$)** : avoir un parent diplômé multiplie par près de 3 la cote d'orientation favorable. Cet impact, largement supérieur à celui du GPA, souligne l'importance du capital culturel familial.

```
H0: Parallel Regression Assumption holds
> print(brant_test)
              x2 df probability
Omnibus 0.72942810 2 0.6943952
gpa      0.70397577 1 0.4014510
pared1   0.09128666 1 0.7625478
> |
```

Nous avons également fait le test de Brant sur le modèle retenu (modèle 2), et on observe que l'hypothèse des lignes parallèles n'est pas rejetée. Le test omnibus donne une statistique de 0,73 avec une p-valeur de 0,69, et aucune des variables prises individuellement (GPA : $p = 0,40$; Pared : $p = 0,76$) ne viole cette



hypothèse. L'effet du GPA et de l'éducation parentale est supposé identique que l'on passe de « peu probable » à « probable » ou de « probable » à « très probable ».

5.2 Effets marginaux

Les **effets marginaux moyens** traduisent les variations de probabilité par unité de chaque variable :

Variable	Catégorie « peu probable »	« probable »	« très probable »
+1 point de GPA	-14,1 pp	+8,9 pp	+5,3 pp
Parent diplômé (0 → 1)	-25,1 pp	+13,3 pp	+11,8 pp

Passer de 2,5/4 à 3,5/4 de moyenne réduit de 14 points la probabilité d'être dans la catégorie *peu probable* et en ajoute 5 dans *très probable*. De même, le simple fait d'avoir un parent diplômé réduit de 25 points la probabilité d'être *peu probable* et augmente de près de 12 points celle d'être *très probable*. Ces effets confirment l'importance combinée de la performance scolaire et du capital éducatif familial.



Les graphiques des effets marginaux ci-dessus montrent que le GPA et l'éducation parentale ont un impact positif complémentaire sur l'accès aux études supérieures. Nous observons qu'un GPA élevé augmente la probabilité d'appartenir à une catégorie plus favorable à l'enseignement supérieur, quel que soit le niveau d'études des parents. De plus, avoir un parent diplômé réduit la probabilité d'être "unlikely" et renforce les chances d'être "somewhat" ou "very likely". Ces deux facteurs augmentent ensemble la probabilité d'une orientation favorable vers l'enseignement supérieur.

6. Discussion

Deux résultats ressortent :


1. **Rendement scolaire** : l'amélioration des notes reste un levier significatif, même après contrôle du milieu familial.
2. **Capital éducatif des parents** : son influence, presque triplement des chances, suggère que l'information et l'accompagnement des familles peu diplômées constituent un axe prioritaire pour réduire les disparités d'orientation.

Le type d'établissement (public / privé) n'apparaît pas discriminant à caractéristiques équivalentes. Cela pourrait signifier soit une homogénéité de qualité dans l'échantillon, soit la prépondérance d'autres facteurs (ressources pédagogiques, effet de pairs) non observés ici

IV. Diagnostic et graphiques : Une étude approfondie du modèle choisi

Dans cette partie, nous allons nous focaliser essentiellement sur le modèle 2 choisi, le but est de diagnostiquer la qualité du modèle, visualiser son fonctionnement et d'en proposer une analyse détaillée.

1. Interprétation du graphique "Proba prédite (very likely) en fonction du GPA"



Ce graphique présente la relation entre la moyenne pondérée (GPA) et la probabilité prédite par notre modèle 2 d'être classé dans la catégorie "very likely" (très probable d'accéder aux études supérieures). En effet, chaque point des nuages correspond à un individu, avec en abscisse son GPA, et en ordonnée la probabilité prédite. Quant à la courbe bleue, elle correspond à une tendance moyenne estimée qui permet de visualiser la forme globale de la relation entre les deux variables. Nous observons qu'il y a une augmentation de la probabilité d'être classé dans la catégorie "very likely" avec l'augmentation du GPA, ce


qui confirme l'idée que la performance scolaire est un déterminant essentiel de l'intention de faire des études supérieures. De plus, nous remarquons que les points du nuage forment deux bandes parallèles et croissantes, il s'agit du fait que le modèle inclut également la variable explicative binaire pared, qui précise si l'élève a au moins un parent diplômé de l'enseignement supérieur. Pour un même niveau de GPA, les individus ayant au moins un parent est diplômé (pared = 1) présentent des probabilités systématiquement plus élevées d'être classés comme "very likely", ce que nous pourrions détecter à travers la bande supérieure dans le nuage de points, par ailleurs, les individus sans parent diplômé (pared = 0) forment eux la bande inférieure. Finalement, la courbe bleue, qui résume la tendance générale illustre l'effet moyen combiné du GPA et de l'éducation parentale sur la probabilité d'aspirer à des études supérieures. L'ensemble de ces éléments valide graphiquement notre modèle.

2. Interprétation des Odds Ratios

```
> print(round(OR_table, 3))
      OR 2.5 % 97.5 %
gpa    1.830 1.115  3.022
pared1 2.845 1.693  4.806
> |
```

Ce tableau présente les **odds ratios cumulés (OR)** issus de notre modèle ainsi que leurs **intervalles de confiance à 95 %**. Les résultats obtenues montrent que le **GPA** et l'**éducation parentale (pared)** ont un impact significatif et positif sur la probabilité d'aspirer à des études supérieures. A savoir, une augmentation d'une unité

du **GPA** multiplie les chances d'être dans une catégorie supérieure de *apply* par **1.83** (soit une augmentation relative de 83%, et un intervalle de confiance à 95% : [1.12 - 3.02]). Par ailleurs, le fait d'avoir **au moins un parent diplômé (pared = 1)** multiplie ces chances par **2.85** (augmentation relative de 185% et intervalle de confiance : [1.69 - 4.81]), soulignant de ce fait l'influence déterminante du niveau d'éducation des parents. Ces effets sont statistiquement significatifs (les intervalles de confiance excluent 1) et robustes, même si l'impact du GPA est plus incertain comme son intervalle est plus large.



Ces résultats peuvent être visualiser également dans ce graphique présentant les odds ratios (OR) de notre modèle qui explique la probabilité d'accès aux études supérieures en fonction des variables GPA et Pared. Comme déjà constaté, les deux variables ont un effet positif et significatif : avoir au moins un parent diplômé (OR $\approx$ 2 graphiquement) et une meilleure moyenne (OR $\approx$ 2.5 graphiquement) augmentent sensiblement la probabilité d'être very likely. De plus, comme les intervalles de confiance à 95 % ne recoupent pas 1, ce qui confirme la significativité des effets observés.

3. Interprétation des AIC, Pseudo-R2 et test LR (de vraisemblance)

Afin d'évaluer la qualité du modèle ordinal logistique retenant les variables gpa (moyenne pondérée) et pared (niveau d'études des parents), plusieurs indicateurs statistiques ont été examinés, certains ont été déjà abordés dans la partie modélisation mais seront mentionnés de nouveau rapidement.

```
> AIC(modelnull, model1, model2, model3, model_interaction)
      df      AIC
modelnull      2 745.2053
model1         3 738.6000
model2         4 725.0638
model3         5 727.0249
model_interaction 5 727.0209
> |
```

Tout d'abord, le critère d'information d'Akaike (AIC) : nous trouvons ici que le modèle 2 présente l'AIC le plus faible (725.06), indiquant le meilleur compromis entre ajustement et complexité parmi les modèles testés.

```
> print(pseudoR2)
      11h      11hnull      G2      McFadden      r2ML
-358.53189415 -370.60264132 24.14149432 0.03257059 0.05856854
      r2CU
0.06945689
```

De plus, les **pseudo-R²** donnent une idée sur la proportion de la variance expliquée. Les résultats de ce tableau de pseudo-R² montre une

amélioration modeste mais non négligeable par rapport au modèle nul, avec un **McFadden R² de 0.033**, typique pour les modèles de type logistique. Les autres indices (r2ML = 0.0586 ; r2CU = 0.0695)

confirment que, même si la variance expliquée est limitée, le modèle apporte quand même une contribution significative à la prédiction.

```
Response: apply
Model Resid. df Resid. Dev Test Df LR stat. Pr(Chi)
1 1 398 741.2053
2 gpa + pared 396 717.0638 1 vs 2 2 24.14149 5.724547e-06
>
```

Concernant le **test de rapport de vraisemblance (LR Test)** soutient cette conclusion, puisque la comparaison entre le

modèle nul et le modèle avec gpa et pared donne une **valeur p très significative ($p < 0.00001$)**. Ce qui signifie que l'ajout de ces deux variables améliore significativement le pouvoir explicatif du modèle, donc une amélioration significative par rapport au modèle nul a eu lieu.

Finalement, même si les pseudo- R^2 soient relativement modestes, l'ensemble des indicateurs statistiques valident la qualité du **modèle 2** comme le modèle final. De plus, d'autres critères seront pris en considération. Il est également important de mentionner que le test de Brant a déjà été fait dans la partie modélisation.

4. Interprétation de la matrice de confusion et du taux d'erreur

La performance du modèle a été évaluée via une matrice de confusion, qui permet de comparer les classes prédites par le modèle avec les classes réelles de la variable apply. Toutefois, vu que la matrice de confusion n'est pas très bien adaptée au modèle ordinal puisqu'elle ne prend en compte que la classe avec la probabilité maximale sans les autres catégories, nous avons décidé d'inclure également un score de Brier cumulatif pour évaluer la qualité des prédictions et donc du modèle.

```
> print(conf_matrix)
      Réel \ Prédit
      unlikely somewhat likely very likely
unlikely      201          19          0
somewhat likely 110          30          0
very likely     27          13          0
>
> cat("Taux d'erreur de prédiction :", round(taux_erreur, 3), "\n")
Taux d'erreur de prédiction : 0.422
```

Commençons en premier avec la matrice de confusion, les résultats montrent que le modèle classe bien les individus dans la catégorie "unlikely" (201 cas correctement prédits sur 220), mais échoue totalement à prédire correctement les cas "very likely" (0 prédiction

correcte). Ajoutons à cela, sur un total de 400 observations, seules 231 ont été correctement classées, soit un taux d'erreur de 42,2 %. Ce résultat révèle une asymétrie dans la performance du modèle, néanmoins la vraie raison est le fait que la matrice de confusion n'est pas l'outil le mieux adapté pour tester la qualité de notre modèle. En fait, bien que la matrice de confusion soit un outil classique pour évaluer la qualité d'un modèle de classification, son utilisation ici est limitée puisque notre modèle est ordinal. Cela signifie qu'il prédit une probabilité cumulative plutôt qu'une classe précise. En forçant une classification à 3 classes ('unlikely', 'somewhat likely', 'very likely'), nous perdons une partie de l'information, ce qui peut expliquer les mauvaises performances sur la classe 'very likely'."


De ce fait, nous avons décidé d'utiliser le score cumulatif de Brier qui mesure également la qualité des prédictions, nous avons choisi la version cumulative parce qu'elle prend en compte l'ordre logique des catégories ce qui fait qu'elle est mieux adaptée à notre modèle ordinal. Le score de Brier varie entre 0 et

1 avec 0 indiquant des prédictions parfaites, donc moins le score est, mieux est la qualité prédictive du modèle.

```
> print(brier_score_cum)
[1] 0.3217226
```




Nous avons eu un score de 0.3217 pour notre modèle 2, montrant ainsi une qualité de prédiction raisonnable, en particulier dans un cadre ordinal.

5. Interprétation de la courbe ROC, du AUC et d'autres graphiques



En dépit du fait qu'il s'agit d'un modèle logit ordinal adapté à des classes ordonnées ("unlikely", "somewhat likely", "very likely"), nous avons mené une évaluation simplifiée par une courbe ROC (montrant la capacité d'un modèle à **discriminer les classe**). Pour cela, la variable apply a été binarisée : "very likely" codée 1, les autres 0. C'est ainsi que nous avons extrait la probabilité associée à la classe 'very likely', dérivée des probabilités cumulatives, afin de tracer la courbe ROC et calculer l'AUC (aire sous la ROC, plus c'est proche de 1, meilleure est la performance du modèle). Nous avons observé

comme résultats une AUC de 0.623, qui montre que dans 62,3 % des cas, un individu réellement "very likely" reçoit une probabilité plus élevée qu'un autre ne l'étant pas. Cette performance, même si modeste, dépasse le hasard (AUC = 0.5), présentant ainsi une certaine capacité de discrimination. Toutefois, il est important de mentionner que cette approche binaire ignore l'ordre des classes et ne reflète pas la performance globale du modèle ordinal. Pour dépasser ce problème, des boxplots ont été générés. Ces derniers comparent les probabilités prédites pour chaque modalité en fonction de la classe réelle.



Le premier boxplot (en rouge) montre que les "unlikely" reçoivent généralement des scores cohérents, mais avec une sur-prédiction sur l'ensemble. Le second suggère que le modèle capture partiellement la progression intermédiaire ("somewhat likely"), malgré un fort chevauchement. Le troisième montre que, même si la classe 'very likely' n'a pas toujours été prédite correctement, les individus appartenant à cette classe reçoivent tout de même des scores plus élevés que les autres, ce qui est cohérent avec l'AUC

obtenue. Ces boxplot montrent une meilleure lecture du comportement du modèle. Elles révèlent donc une certaine logique dans les scores prédites suivant l'ordre des classes, une logique que la ROC seule ne permet pas de juger, ce qui montre l'importance d'évaluations spécifiques aux modèles ordonnés.

V. Conclusion

En conclusion, notre analyse entamée par le modèle ordinal logistique présente la pertinence des deux variables principales retenues : la performance scolaire (GPA) ainsi que le capital éducatif familial (Pared). De plus, le modèle 2, choisi pour son équilibre entre simplicité et efficacité, présente des résultats cohérents graphiquement et statistiquement, avec le test de Brant qui valide l'hypothèse des lignes parallèles, ce qui renforce la fiabilité des effets estimés. Nous avons ainsi trouvé à travers nos résultats qu'une meilleure moyenne scolaire augmente sensiblement les chances de viser des études supérieures, et le fait d'avoir au moins un parent diplômé les multiplie plus significativement. Ces effets, confirmés par les odds ratios et les visualisations tout au long de notre rapport, soulignent un potentiel intérêt de politiques ciblées vers les familles peu diplômées.

En termes de qualité prédictive, quoique certains indicateurs comme le pseudo- R^2 ou la matrice de confusion puissent sembler modestes, ils restent quand même conformes aux standards de ce type de modèle. Des outils plus adaptés au logit ordinal, tels que le score de Brier cumulatif et les visualisations ordinales, offrent une lecture plus adéquate et montrent que les probabilités prédites suivent globalement l'ordre attendu des catégories.

De ce fait, malgré quelques limites classiques liées à la nature des données et des outils de mesures, le modèle retenu présente une base solide, interprétable ainsi que pertinente pour comprendre les déterminants de l'orientation post-bac. Néanmoins, une base de données plus riche, intégrant davantage de variables explicatives, permettrait potentiellement de renforcer la précision et la portée du modèle pour de futures analyses.